

Análisis Comparativo de Intrones en Programación Genética mediante Regresión Simbólica: Estudio de Métodos de Selección bajo $F=\{+\}$ y $F=\{+, \times\}$

SANDRA ALITZEL VÁZQUEZ CHÁVEZ

Resumen—El presente trabajo realiza un análisis comparativo de regresión simbólica mediante Programación Genética (PG), con el objetivo de estudiar el fenómeno de los *intrones* terminales o subárboles que no contribuyen al valor de *fitness* del individuo bajo distintas configuraciones de selección y operadores genéticos. Se evalúan dos experimentos que difieren en el conjunto de funciones primitivas: $F=\{+\}$ y $F=\{+, \times\}$, con terminales $T=\{0, 1, 4\}$ y objetivo $\text{suma} = 10$. En cada experimento se comparan tres métodos de selección: Torneo ($k=7$), Boltzmann ($T_b=1$) y Vasconcelos. La implementación se desarrolló en Python con una aplicación interactiva en Streamlit. Los resultados muestran que Torneo y Boltzmann son funcionalmente equivalentes y exhiben intronización con terminales neutros bajo $F=\{+\}$, mientras que la introducción de $\times$ rompe el monopolio de intrones y favorece mayor diversidad terminal. Vasconcelos produce colapso poblacional en ambos experimentos, con consecuencias numéricamente catastróficas bajo $F=\{+, \times\}$.

Index Terms—Programación Genética, Intrones, Regresión Simbólica, Selección por Torneo, Selección de Boltzmann, Selección de Vasconcelos, Mutación Mixta.

I. INTRODUCCIÓN

La Programación Genética (PG) es una rama de la computación evolutiva que evoluciona automáticamente expresiones simbólicas representadas como árboles [1]. Uno de los fenómenos más estudiados en PG es el de los *intrones*: nodos o subárboles cuya presencia no afecta el valor de salida ni el *fitness*, pero que se acumulan a lo largo de las generaciones aumentando el tamaño de los árboles sin beneficio aparente. Este crecimiento estructural no funcional, conocido también como *bloat*, representa un problema práctico relevante pues incrementa el costo computacional y dificulta la interpretabilidad de las soluciones.

El presente trabajo estudia la formación y distribución de intrones bajo distintos métodos de selección, utilizando como banco de prueba la tarea de regresión simbólica con objetivo $\text{suma} = 10$. Se comparan tres estrategias: Torneo ($k=7$), Boltzmann ($T_b=1$) y Vasconcelos, en dos escenarios definidos por el conjunto de operadores disponibles. El análisis se realiza a través de cinco métricas: evolución del *fitness*, conteo de terminales, profundidad de árboles, tamaño de árboles (nodos) y diversidad poblacional.

II. CONFIGURACIÓN EXPERIMENTAL

II-A. Hiperparámetros comunes

La Tabla I resume los parámetros fijos en ambos experimentos.

Cuadro I: Hiperparámetros comunes a ambos experimentos

Parámetro	Valor
Terminales	$T = \{0, 1, 4\}$
Objetivo	$\text{suma} = 10$
Tipo de mutación	Mixta (nodo + subárbol)
Probabilidad de cruza	0.9
Probabilidad de mutación	0.1
Máx. generaciones	1 000
Número de individuos	500
Máx. nodos	128
Profundidad máxima	7
Elitismo	2 mejores

II-B. Variable entre experimentos

- **Experimento 1:** $F = \{+\}$
- **Experimento 2:** $F = \{+, \times\}$

II-C. Métodos de selección evaluados

- **Torneo** ($k=7$): selección determinista por torneo de tamaño 7.
- **Boltzmann** ($T_b=1$): selección probabilística basada en la distribución de Boltzmann con temperatura $T_b=1$.
- **Vasconcelos**: método de selección basado en el esquema propuesto por Vasconcelos.

II-D. Implementación

La implementación se realizó en Python utilizando Streamlit como interfaz interactiva, lo que permite variar los hiperparámetros en tiempo real y comparar resultados entre experimentos de forma visual e inmediata.

III. EXPERIMENTO 1 $F = \{+\}$

III-A. Evolución del Fitness




Figura 1: Exp. 1 Evolución del *fitness* (|resultado – objetivo|). Verde: mejor individuo. Azul punteado: promedio.

El mejor individuo alcanza $fitness = 0$ desde las primeras generaciones en los tres métodos, preservado por el elitismo. **Torneo** y **Boltzmann** muestran un descenso gradual del promedio poblacional desde $\approx 3,5$ hasta estabilizarse en $\approx 1,0-1,5$ alrededor de la generación 200, evidenciando una mejora colectiva sostenida. Boltzmann converge ligeramente más rápido en las primeras generaciones por su mayor presión selectiva inicial. **Vasconcelos** no ejerce presión selectiva efectiva: su promedio escala hasta ≈ 200 y se mantiene sin tendencia de mejora durante las 1 000 generaciones.

III-B. Conteo de Terminales Análisis de Intrones




Figura 2: Exp. 1 Conteo total de terminales en la población. Rojo: 0; Azul: 1; Verde: 4.

En **Torneo** y **Boltzmann** el terminal 0 escala explosivamente hasta $\approx 20\,000-25\,000$ ocurrencias antes de la generación 100, mientras 1 y 4 colapsan a cero. Dado que $F = \{+\}$, sumar cero no altera ningún resultado: 0 es un *intrón puro*. En **Vasconcelos** el terminal 4 domina ($\approx 28\,000-30\,000$), generando sumas masivamente alejadas del objetivo un *intrón de deriva*. La Tabla II resume este análisis.

Cuadro II: Exp. 1 Síntesis del análisis de intrones

Método	Term. dom.	Ocurrencias	Tipo intrón
Torneo $k=7$	0	20k–25k	Neutro (puro)
Boltzmann $T_b=1$	0	18k–22k	Neutro (puro)
Vasconcelos	4	28k–30k	Deriva

III-C. Profundidad de Árboles




Figura 3: Exp. 1 Profundidad de árboles. Izq.: mejor árbol (púrpura), promedio (naranja), máximo (rojo punteado). Der.: comparativa de profundidad promedio entre métodos.

Torneo y Boltzmann exhiben trayectorias prácticamente idénticas, estabilizándose en $\approx 14-17$ nodos de profundidad promedio (Fig. 3b). Sus mejores árboles se fijan en profundidad $\approx 4-8$, evidenciando una brecha estructural por acumulación de intrones neutros. La comparación con Vasconcelos (Fig. 3c) revela una brecha de ≈ 18 unidades sostenida durante todo el experimento: Torneo mantiene $\approx 3-4$ nodos promedio mientras Vasconcelos escala hasta $\approx 20-22$ y sigue creciendo, evidenciando *deriva estructural progresiva*.

III-D. Tamaño de Árboles (Nodos)




Figura 4: Exp. 1 Tamaño promedio de árboles (nodos). Límite máximo: 128 nodos.

Torneo y Boltzmann crecen hasta $\approx 85-100$ nodos (66–78 % del límite). Vasconcelos satura el límite de 128 nodos desde la generación 50 y permanece en $\approx 115-125$ nodos, con el límite de nodos como único freno al crecimiento. Torneo produce árboles de tan solo $\approx 15-20$ nodos promedio en comparación directa con Vasconcelos, demostrando que una selección efectiva contiene el *bloat* de forma natural (Tabla III).

Cuadro III: Exp. 1 Tamaño promedio de árboles

Método	Nodos prom.	% límite máx.
Torneo $k=7$	95–100	74–78 %
Boltzmann $T_b=1$	85–95	66–74 %
Vasconcelos	115–125	90–98 %

III-E. Diversidad Poblacional




Figura 5: Exp. 1 Diversidad poblacional (desviación estándar del *fitness*).

Torneo y Boltzmann mantienen una desviación estándar estable en $\approx 2,5-3,0$, sin tendencia hacia cero: la mutación mixta introduce variabilidad continua que equilibra la presión selectiva. Vasconcelos escala hasta $\approx 50-65$, una dispersión que no refleja diversidad útil sino **colapso poblacional**: coexisten el élite con *fitness* = 0 y una masa mayoritaria con *fitness* ≈ 200 .

IV. EXPERIMENTO 2 $F = \{+, \times\}$

IV-A. Evolución del *Fitness*




Figura 6: Exp. 2 Evolución del *fitness*. Verde: mejor individuo. Azul punteado: promedio.

La introducción de $\times$ amplifica radicalmente las diferencias entre métodos. El mejor individuo alcanza *fitness* = 0 desde las primeras generaciones en los tres casos. **Torneo** mantiene el promedio cercano a 0 con dos picos transitorios de hasta $\approx 3B$ (generaciones ≈ 410 y ≈ 920), producto de cruza que generan multiplicaciones profundamente anidadas, eliminadas en la siguiente generación. **Boltzmann** presenta un único pico de $\approx 2B$ alrededor de la generación 520, más contenido que Torneo. **Vasconcelos** exhibe una escalada escalonada permanente desde la generación 200 hasta estabilizarse en $\approx 1,5 \times 10^{38}$ un colapso numérico irreversible generado por la proliferación de 4 en cadenas de multiplicaciones sin control selectivo.

IV-B. Conteo de Terminales Análisis de Intrones




Figura 7: Exp. 2 Conteo total de terminales en la población. Rojo: 0; Azul: 1; Verde: 4.

El hallazgo más relevante del Experimento 2 es que la multiplicación **rompe el monopolio de intrones** en Torneo y Boltzmann: los tres terminales coexisten de forma competitiva (≈ 4000 – 9000 cada uno), sin que ninguno domine de forma absoluta. Esto ocurre porque con $\times$ ningún terminal es completamente neutro: 0 anula productos, 1 es neutro en multiplicación, y 4 amplifica exponencialmente. La diversidad terminal refleja que distintas combinaciones son igualmente competitivas. En **Vasconcelos** el terminal 4 domina masivamente (≈ 30000), ahora con consecuencias exponencialmente más graves por la multiplicación disponible.

IV-C. Profundidad de Árboles




Figura 8: Exp.2 Profundidad promedio comparativa entre métodos.

Torneo y Boltzmann convergen a ≈ 16 – 19 antes de la generación 50 más rápido que en Exp.1 y se mantienen equivalentes. La comparación con Vasconcelos revela una **inversión**: mientras en Exp.1 Vasconcelos producía árboles más profundos (≈ 20 – 22) que Torneo (≈ 3 – 4), en Exp.2 Vasconcelos desciende a ≈ 13 – 14 y Torneo alcanza ≈ 17 – 19 . La saturación numérica actúa como freno implícito: árboles muy profundos con multiplicaciones de 4 generan valores que colapsan el sistema incluso bajo la débil presión de Vasconcelos.

IV-D. Tamaño de Árboles (Nodos)




Figura 9: Exp.2 Tamaño promedio de árboles (nodos). Límite máximo: 128 nodos.

Torneo y Boltzmann se estabilizan en ≈ 78 – 88 nodos (61–69% del límite), **menos** que en Exp.1 (≈ 85 – 100), evidenciando mayor eficiencia simbólica: $\times$ permite expresar el objetivo con menos nodos. Vasconcelos satura el límite de 128 nodos desde la generación 50 en ambos experimentos. La Tabla IV compara los tamaños entre experimentos.

Cuadro IV: Tamaño promedio comparativa entre experimentos

Método	$F=\{+\}$	$F=\{+, \times\}$	Cambio
Torneo $k=7$	95–100	78–88	–15 nodos
Boltzmann $T_b=1$	85–95	75–85	–10 nodos
Vasconcelos	115–125	120–125	Sin cambio

IV-E. Diversidad Poblacional




Figura 10: Exp.2 Diversidad poblacional (desviación estándar del fitness).

Torneo y Boltzmann presentan desviación estándar ≈ 0 durante casi todo el experimento, con picos impulsivos aislados de hasta $\approx 65B$ (Torneo) y $\approx 42B$ (Boltzmann), de duración de 1–2 generaciones. Esto indica **convergencia poblacional real**: casi todos los individuos están próximos al óptimo. Vasconcelos escala escalonadamente hasta $\approx 1,5 \times 10^{38}$ de forma permanente una dispersión $\approx 10^{25}$ veces mayor que los picos de Torneo reflejando colapso numérico estructural.

IV-F. Mejores Individuos Encontrados

La Tabla V presenta los mejores árboles hallados por cada método al finalizar las 1000 generaciones.

Cuadro V: Exp.2 Resumen de mejores individuos

Método	Fitness	Gen.	Prof.	Expresión (núcleo)
Torneo	0.0000	0	2	$((1+4) \times (1+1))$
Boltzmann	0.0000	0	7	$(0 \times 0) + (1 \times ((1+1 \times 4) \times (\dots)))$
Vasconcelos	0.0000	0	7	$4 + (((1+4) + (1 \times 0)) + (\dots))$

Torneo produce la solución : $(1+4) \times (1+1) = 5 \times 2 = 10$, con profundidad 2, 7 nodos y cero intrones. **Boltzmann** llega al mismo resultado numérico pero envuelto en intrones explícitos (0×0 , $0+0$), con profundidad 7. **Vasconcelos** alcanza fitness = 0 con la expresión más cargada de intrones: múltiples términos nulos (1×0 , 4×0 , $0+0$) ocultan el núcleo funcional $4 + (1+4) + \text{ceros} = 10$.

V. DISCUSIÓN

V-A. Equivalencia Torneo–Boltzmann

En ambos experimentos, Torneo y Boltzmann producen resultados prácticamente idénticos en todas las métricas evaluadas. La mutación mixta combinada con selección moderada genera el mismo equilibrio exploración–explotación. La única diferencia observable es que Boltzmann converge ligeramente más rápido en las primeras generaciones y produce árboles marginalmente más pequeños, producto de su mecanismo probabilístico que reduce la probabilidad de propagar individuos aberrantes.

V-B. Impacto del Operador $\times$ sobre los Intrones

La introducción de la multiplicación transforma cualitativamente el fenómeno de intronización. Bajo $F=\{+\}$, el terminal 0 es neutro absoluto y monopoliza la población en Torneo y Boltzmann. Con $F=\{+, \times\}$, ningún terminal es completamente neutro, lo que genera diversidad terminal

genuina y permite encontrar soluciones más compactas como la expresión de profundidad 2 hallada por Torneo.

V-C. Fracaso Sistemático de Vasconcelos

Vasconcelos falla en ambos experimentos, pero con gravedad cualitativamente diferente. Bajo $F=\{+\}$ produce un colapso moderado (promedio ≈ 200); bajo $F=\{+, \times\}$ el colapso es catastrófico ($\approx 10^{38}$), con una diferencia de $\approx 10^{36}$ entre experimentos. La multiplicación actúa como amplificador exponencial de las deficiencias del método de selección.

VI. CONCLUSIONES

1. **Torneo y Boltzmann son funcionalmente equivalentes** bajo las configuraciones evaluadas. Ambos encuentran la solución óptima, mantienen poblaciones estructuralmente controladas y exhiben niveles saludables de diversidad.
2. **La intronización es universal pero dependiente del operador.** Bajo $F=\{+\}$, Torneo y Boltzmann producen intrones neutros (0); bajo $F=\{+, \times\}$, la multiplicación elimina el terminal neutro absoluto, reduciendo el *bloat* y mejorando las soluciones.
3. **Vasconcelos falla sistemáticamente.** No ejerce presión selectiva efectiva, produce colapso poblacional y genera los árboles más cargados de intrones. La multiplicación agrava este fracaso de forma exponencial.
4. **La selección efectiva es el principal mecanismo de control del *bloat*.** El límite de nodos y el elitismo por sí solos no son suficientes para contener el crecimiento arbóreo no funcional, como lo demuestra el comportamiento de Vasconcelos.

REFERENCIAS

- [1] J. R. Koza, *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, Cambridge, MA, 1992.